



Data-Driven Decision Making Ecommerce

Réalisée par:

Anas El Midaoui & Ihssan Ben Labsir

Juin 2026

Contexte & Problématique



Contexte Wide World Importers est une entreprise de distribution e-commerce commercialisant des produits dans 4 catégories :

- Packaging Materials, Clothing, Novelty Items, Toys.

Question décisionnelle centrale :

- "Quels segments clients et quelles catégories de produits maximisent le chiffre d'affaires et la marge brute ?"

Données analysées : 228 264 transactions | 663 clients | 227 produits | Période 2013–2016



Sources de Données



Source 1 — Wide World Importers (Microsoft SQL Server)

- fact_ventes.csv : 228 264 transactions de ventes
- dim_client.csv : 663 clients
- dim_produit.csv : 227 produits

Source 2 — Olist E-commerce (Kaggle)

- olist_order_items_dataset.csv : 112 650 transactions
- Dataset complémentaire utilisé pour la contextualisation et la comparaison des prix du marché e-commerce brésilien



Audit des Données



Résultats de l'audit qualité

✓ Valeurs manquantes : 0 sur toutes les colonnes financières ✓ Doublons détectés : 0 ✓ Types de données : tous corrects (int64 / float64 / datetime) ✓ Cohérence temporelle : 2013 → 2016

Statistiques descriptives (Fact_Ventes) :

- CA moyen / transaction : 754.65 USD
- Marge brute moyenne : 375.57 USD
- Asymétrie (skewness) CA : 5.29 → distribution à forte queue droite



Découvertes EDA – KPIs Globaux




Chiffres clés – Source : Power BI Dashboard



CA Total : 172.26 M USD



Marge Brute Totale : 85.73 M USD



Taux de Marge Global : 49.77%



Nombre de clients : 663





Nombre de produits : 227

Catégorie dominante :

Packaging Materials = 58.44% du CA



Analyse des catégories



Tests Statistiques



Test 1 — ANOVA : CA par Catégorie Produit F-statistique = 8 688.16 | p-value = 0.000000

- La catégorie produit a un impact statistiquement significatif sur le CA

Test 2 — T-Test : Packaging Materials vs Novelty Items CA moyen Packaging : 1 452.12 USD CA moyen Novelty : 395.98 USD t = 116.69 | p-value = 0.000000

- Différence significative : Packaging génère ×3.7 plus de CA



Test 3 — Chi-2 : Catégorie × Segment → Association testée dans le notebook
Section 5.3



Comparaison des Prix – 2 Sources



Comparaison des Structures de Prix — WWI vs Marché E-commerce Brésilien



Comparaison des Prix – 2 Sources



Enrichissement : WWI vs Marché E-commerce (Olist/Kaggle)

	WWI	Olist
Prix moyen	45.59 USD	120.65 USD
Prix médian	18.00 USD	74.99 USD
Écart-type	139.86	183.63

Interprétation :

WWI est positionné sur le segment prix bas/moyen.
Le marché e-commerce brésilien a un panier moyen ×2.6 plus élevé.

Opportunité identifiée :


marge de progression sur le panier moyen WWI.




Segmentation Clients K-Means



Méthode : K-Means avec k=3
(méthode du coude)
Cluster 0 – Clients Standard
CA total faible | Fréquence
d’achat basse
Cluster 1 – Clients
Intermédiaires CA modéré |
Fréquence moyenne
Cluster 2 – Clients Haute
Valeur CA élevé | Forte
fréquence | Marge élevée
→ Les clients Haute Valeur
concentrent la majorité du CA



Modélisation Prédictive





Modélisation Prédictive

Objectif : Prévoir le CA mensuel
Feature engineering : TimeIndex, CA_Lag1, CA_Lag2, Nb_Transactions, Qte_Vendue, Mois

Comparaison des 3 modèles :

Modèle	RMSE	R ²
Régression Linéaire	221992.28	0.3554
Random Forest	171464.59	0.6154
Gradient Boosting	145504.64	0.7231


Validation K-Fold k=5 — Random Forest : R² moyen = 0.8189 +/- 0.0580



Interprétabilité SHAP



SHAP — Importance Globale des Variables



Interprétabilité SHAP



Pourquoi le modèle prédit un CA élevé ?

Les SHAP values révèlent les variables les plus influentes :

1. CA_Lag1 → La tendance récente des ventes est le facteur le plus prédictif
 2. Nb_Transactions → Le volume d'activité influence fortement le CA
 3. Qte_Vendue → Les quantités vendues
 4. Mois → Effet saisonnalité détecté
 5. TimeIndex → Tendance temporelle croissante
- Le CA futur dépend surtout du CA récent et du volume de transactions



Recommandations



● Recommandation 1 — HAUTE PRIORITÉ Renforcer la catégorie Packaging Materials

Constat : Packaging représente 58.44% du CA total et un CA moyen de 1 452 USD/transaction (×3.7 vs Novelty Items — confirmé par T-test, $p < 0.0001$)

Action recommandée : Augmenter les stocks, les promotions et la visibilité de la catégorie Packaging Materials

Impact potentiel estimé : +2% du CA de la catégorie = +3.4 M USD/an (Scénario basé sur une augmentation de 2% du CA actuel de Packaging):

● Recommandation 2 — HAUTE PRIORITÉ Fidéliser les clients Haute Valeur (Cluster 2)

Constat : Le Cluster 2 (K-Means) concentre les clients les plus rentables Action : Programme de fidélité dédié + account manager personnel Impact potentiel estimé : Réduction du churn → +2.57 M USD/an (Estimation basée sur le CA moyen de Cluster 2)

● Recommandation 3 — PRIORITÉ MOYENNE Convertir les clients Standard en Premium

Constat : Frontière claire entre Cluster 0 et Cluster 2 visible dans le K-Means Action : Offres personnalisées pour les clients

Standard à fort potentiel Impact potentiel estimé : +1% CA → +1.72 M USD/an





Plan A/B Test

Objectif : Valider si une campagne promotionnelle sur Packaging Materials augmente le CA de $\geq 10\%$

Paramètre

Valeur

H_0	La campagne ne change pas le CA moyen
H_1	La campagne augmente le CA de $\geq 10\%$
Groupe A	Transactions Packaging sans promotion (contrôle)
Groupe B	Transactions Packaging avec promotion (traitement)
Test statistique	T-test bilatéral de Welch — $\alpha = 0.05$
Taille d'échantillon	50 transactions par groupe
Durée	3 mois (Juillet → Octobre 2026)
 Critère de succès	$p\text{-value} < 0.05$ ET augmentation $\geq 10\%$



Business Case & ROI

CA Total historique : **172.26 M USD** Marge Brute Totale : **85.73 M USD** Taux de Marge Global : **49.77%**

Impact potentiel des 3 recommandations :

Recommandation	Impact estimé
Packaging focus (+2% CA catégorie)	+3.4 M USD/an
Fidélisation Cluster 2	+2.57 M USD/an
Upgrade Cluster Standard (+1% CA)	+1.72 M USD/an
TOTAL	+7.69 M USD/an

